

介護における音響 HAR と連合学習を用いた異常検知

竹本志恩

June 20, 2025

INIAD

背景と研究目的

- 高齢化社会における介護現場の負担増大
- HAR に着目: 介護者の負担軽減
- センサデータのプライバシー懸念に FL に対処
- 目的: 異常イベントをリアルタイム検知+通知

本研究の独自性

- 複数の異常イベントを同時／複合的に検知
- マルチラベル分類で音響イベントを解釈
 - 画像中のりんごとバナナを識別
 - 咳と苦痛の音が同時に聞こえる > 重篤な状態
 - 転倒に似た音を、他のイベントを基に判断
- マルチラベルイベント検知 + 異常検知
 - どの時間帯に、何のイベントが、どういう組で起こったか識別
 - 深い状況把握と迅速対応を実現

- 利点: 非接触モニタリング＋視覚プライバシー保護
- 課題
 - 環境騒音によるマスキング
 - 高静音性活動の検知が困難
 - 音の多様性／同時発生の問題
- 頑健なモデルが必要

連合学習 (FL) の基礎と HAR への適用

- 分散学習：生データ非共有でモデル協調学習
- プライバシー保護、パーソナル化、通信効率
- 介護現場に適した技術

FL-HARの主要課題

主要課題①：データ関連

- 極端なデータ不均衡（稀イベント、多ラベル共起）
 - 複数異常の組み合わせはほぼない
- Non-IID 分布
 - 各利用者の音響特性や行動の差
- ラベルの関係を捉えたモデリング
- マルチラベルデータセットの不足

主要課題②：モデル・通信・プライバシー

- モデル複雑化 ↔ 通信オーバーヘッド
- リアルタイム通知の遅延リスク
 - イベント検知 → 異常検知の手順を検討中
 - 段階的な処理は推論速度が低下しそう
- マルチラベルによるプライバシーリスクの上昇
 - マルチクラスより情報が増加

主要課題③：パーソナライズ化・継続学習

- 個人差対応のパーソナライズド FL
- コールドスタート：未知の音響組み合わせ
- 音響環境変化への適応

課題解決の戦略

対策①：データ不均衡・Non-IID 対策

- 合成データ生成 (GAN, SMOTE)
- 少数クラスを強調: Time-Balanced Focal Loss[4] など特殊損失
- 集約法の工夫: FedProx[3] など
- モデル統合の効率化: クラスタリング FL / ドメイン適応

対策②：プライバシー強化

- オンデバイス特徴抽出によるデータ最小化
- ノイズ付与: 差分プライバシー (DP)
- 暗号化集約: セキュアアグリゲーション (SA) / 同型暗号 (HE)
- 精度とオーバーヘッドのバランス

対策③：モデル・リソース効率化

- モデル軽量化: モデル圧縮/量子化/枝刈り
- 計算の分割: Federated Split Learning (FSL)[1]
- 通信量削減: 勾配圧縮・選択的更新

- マルチラベル FL フレームワークが存在
- 例: FMML[5], FedMLP[6], FedLGT[7]
- 参考になりそう

- 標準化データセットの整備
- FL 対応マルチラベル損失/新アーキテクチャ開発
|ー マルチラベル FL など参考
- 連合継続学習・因果推論の検討

補足資料

データ不均衡・Non-IID への対応：Time-Balanced Focal Loss [4]

- 概要：持続時間のばらつきによるデータ不均衡を考えた損失関数
- 目的：イベントの発生頻度だけでなく、持続時間も考慮
- 動作原理：
 - 標準的な Focal Loss をクラスごとの重み w_c で拡張
 - w_c は、データ量（音源/クリップ数）とイベント持続時間（フレームの比率 r_c ）を考慮
 - 希少で持続時間の短い音響イベントの学習が強化され、検出精度が向上

プライバシー強化技術：差分プライバシー (DP)

- 目的：個々のデータサンプルの寄与を曖昧にし、漏洩リスクを保証
- 動作原理：
 - モデル更新（勾配や重みなど）にノイズを付加
 - Federated Split Learning (FSL) では、中間活性化情報にガウスノイズ
- 課題：以下のトレードオフ
 - モデルの精度低下
 - 計算・通信オーバーヘッドの増加

リソース効率化技術：Federated Split Learning (FSL)[1]

- 概要：モデルの計算負荷をクライアントとサーバーで分割
- 目的：エッジデバイスの計算能力、メモリ、通信帯域の制約を両立させながら、モデル訓練や推論を効率的に実行
- 動作原理：
 - モデルの層を分割点（‘cut layer’または‘split layer’）で分け、クライアント側でモデルの一部（例：特徴抽出層）を処理し、中間活性化情報をサーバーに送信
 - サーバー側で残りのモデル処理（例：分類層）、損失計算、およびバックプロパゲーションを実行
 - 例: クライアント側に LSTM 層、サーバー側に出力層（Dense+Softmax）を配置

マルチラベルFLフレームワーク：FMLL[5]

- 動作原理：
 - マルチラベルデータセットをバイナリ関連性 (Binary Relevance) 戦略に基づき複数の二値データセットに分解
 - 各二値データセットでローカルモデル（例: REPTree）を訓練し、中央ノードでこれらのローカルモデルを集約してグローバルモデルを作成
- HAR 適用時の課題：
 - 現状、動物科学分野のデータセットで検証されており [33, 35]、HAR 異常データへの直接的な適用性は未検証
 - ベース分類器として REPTree を使用しており、表現力の限界が懸念

マルチラベル FL フレームワーク：FedMLP[6]

- 概要：部分的なアノテーション（欠損ラベル）を持つマルチラベル FL に対応
- HAR 適用時の課題：
 - 医療データセットで検証されている
 - 疑似ラベリングの精度が全体の性能に影響を与える可能性




実装など




FedProx[3]


- FedProx を実装し, FedAvg と比較
- flower+Docker で実装を試みたが中断
- Github の検証用コードを利用:
<https://flower.ai/docs/baselines/fedprox.html>
- これから: 実行結果を配布ノートブックで可視化し, ローカルでの性能を検証
- できれば: クライアント数を段階的に増やし, FedProx と FedAvg を比較

これから: マルチラベル分類

- 日常生活動作について、マルチラベル音響分類を検証
- 使用中の行動認識モデルはスペクトログラムを使うため、画像分類を参考にできそう
- 単純な分類を実装
 - ESC-50 データセットをマルチラベル用に加工、損失関数を変更
 - cf. <https://qiita.com/koshian2/items/ab5e0c68a257585d7c6f>
- より良い分類を実装
 - 実装を探す: <https://paperswithcode.com/task/multi-label-classification> など
 - Transformer でマルチラベル画像分類:
<https://github.com/SlongLiu/query2labels> など参照
 - 並行して異常イベント系のデータ収集/分析、モデル構築/検証が必要

-  J. Ndeko, S. Shaon, A. Beal, A. Sahoo, and D. C. Nguyen, "Federated Split Learning for Human Activity Recognition with Differential Privacy," arXiv:2411.06263, 2024.
-  V. Mothukuri *et al.*, "A survey on security and privacy of federated learning," *Future Generation Computer Systems*, vol. 115, pp. 619 – 640, 2021. doi:10.1016/j.future.2020.10.007.
-  T. Li *et al.*, "Federated Optimization in Heterogeneous Networks," arXiv:1812.06127 [cs.LG, stat.ML], 2020.

-  S. Park and M. Elhilali, "Time-Balanced Focal Loss for Audio Event Detection," ICASSP 2022, pp. 311 – 315.
-  B. Ghasemkhani *et al.*, "Federated Multi-Label Learning (FMML): Innovative Method for Classification Tasks in Animal Science," *Animals*, vol. 14, no. 14, p. 2021, 2024. doi:10.3390/ani14142021.
-  Z. Sun *et al.*, "FedMLP: Federated Multi-label Medical Image Classification Under Task Heterogeneity," *Lecture Notes in Computer Science*, vol. 15010, pp. 394 – 404, 2024. doi:10.1007/978-3-031-72117-5_37.

-  I-Jieh Liu *et al.*, "Language-Guided Transformer for Federated Multi-Label Classification," arXiv:2312.07165, 2023.
<https://arxiv.org/abs/2312.07165>